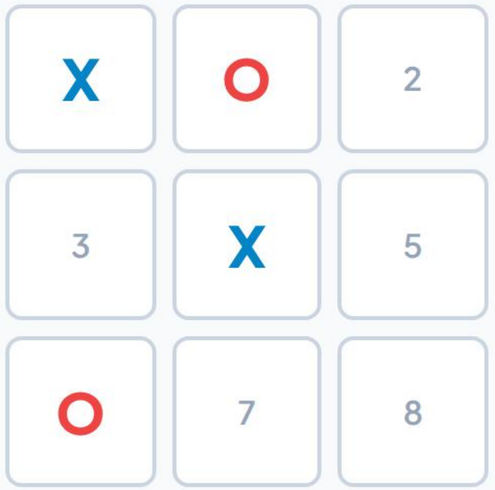
DESAFIO 1 • PROCESSO DE DECISÃO DE MARKOV

Problema Escolhido: Jogo da Velha (Tic-Tac-Toe)

1. Ambientes Parcialmente Observáveis vs. Espaço do Estado Markoviano

MAPEAMENTO DE POSIÇÕES (0 A 8)



Vetor de Estado (S_t)

Representação por um vetor discreto de 9 posições: $S_t = [s_0, s_1, s_2, s_3, s_4, s_5, s_6, s_7, s_8]$.

Codificação dos Símbolos

0: Célula vazia (disponível para jogada)
+1: Célula ocupada pelo Agente (X)
−1: Célula ocupada pelo Oponente (O)

Suficiência Markoviana: O número total de estados válidos é finito ($|S| \le 3^9 = 19.683$, reduzido para ~5.478 estados alcançáveis), permitindo resolução por Tabular Q-Learning.

MODELAGEM DO PDM

2. Espaço de Ações do Agente (A_t) e Transições

Espaço Bruto de Ações

Espaço de ações discreto e estático referente aos 9 slots do tabuleiro:

$$A = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$$

Máscara de Ações Válidas

Filtro de ações viáveis dependente do estado atual S_t:

$$A(S_t) = \{ i \in A \mid s_i = 0 \}$$

Transição Ambiental

A ação a_t altera $s_i \to +1$. O oponente joga em seguida, completando a transição até o próximo estado observável S_{t+1}.

Modelagem de Oponentes: O comportamento do oponente (aleatório, min-max ou heurístico) faz parte da probabilidade de transição de estados $P(S_{t+1} | S_t, A_t)$ do ambiente.

FEEDBACK E RETORNO DO AGENTE

3. Função de Recompensa (R_t) e Retorno Esperado

Sinal de Recompensa Específico

Condição de Término / Evento	Recompensa R_t	Efeito no Treinamento
Vitória (3 alinhados)	+1.0	Reforço positivo para sequências vencedoras
Empate (Velha)	+0.2	Recompensa moderada contra oponentes perfeitos
Derrota	-1.0	Punição máxima para incentivar bloqueio do rival
Jogada Valida em Curso	-0.01	Custo por passo para priorizar vitórias rápidas
Ação Inválida (Tentativa)	-10.0	Penalidade severa para aprendizado do espaço de regras

Objetivo de Aprendizado

Maximizar o retorno acumulado descontado G_t até o fim do episódio:

$$G_t = \sum_{k=0}^{T} \gamma^k R_{t+k+1}$$

Fator de Desconto ($\gamma = 0.95$)

Equilibra a importância de vitórias imediatas em relação à preparação de armadilhas táticas de múltiplos passos (ex: garfos/double threats).